

چت هوشمند

SMART CHAT

اپ چت هوشمند فارسی (RTL) + سرور API سازگار با OpenAI و Anthropic
دو نسخه معادل: Next.js 16 و تک فایل Node خالص

این سند، مرجع کامل پروژه است: معماری و جریان درخواست، پیش‌نیازهای سیستم، راهنمای نصب و اجرا، قابلیت‌ها، مرجع API با نمونه‌های curl، لیست مدل‌ها، تاریخچه توسعه در هفت تسک، مشکلات شناخته‌شده و نقشه راه پیشنهادی. نسخه Markdown همین محتوا کنار کد (README.md) و سند تحویل سریع در HANDOFF.md نگهداری می‌شود.

Next.js 16 · React 19 · Tailwind 4

۱۴ سپتامبر ۲۰۲۶ · ۲۳ شهریور ۱۴۰۵

نسخه سند ۱.۰

app.js — بدون وابستگی

معرفی پروژه | Overview

این پروژه یک اپلیکیشن چت هوشمند کامل است که با هدف کار با سرویس رایگان **freemodels** ساخته شده است. رابط کاربری دقیقاً به سبک ابزارهای مدرن چت AI طراحی شده – تم تاریک، چیدمان راست‌به‌چپ فارسی، فونت Vazirmatn، پیکر مدل گروهی با لوگوی واقعی ارائه‌دهنده‌ها – و پاسخ‌ها به‌صورت زنده (streaming) با نمایش فرایند تفکر مدل (reasoning) رندر می‌شوند. پروژه در قالب **دو نسخه موازی** تحویل داده شده است که هر دو از یک آپستریم مشترک استفاده می‌کنند و رفتار یکسانی دارند.

۱) نسخه src – /Next.js

اپ کامل React 19 با Tailwind CSS 4 و کامپوننت‌های client-side؛ مناسب توسعه آینده، پیش‌نمایش زنده و استقرار استاندارد. نقطه ورود UI فایل `src/app/page.tsx` و بک‌اند در مسیرهای `src/app/v1/*` و `src/app/api/*` است.

۲) نسخه تک‌فایل – app.js

یک فایل CommonJS خالص Node (بدون هیچ وابستگی خارجی) که سرور HTTP، پروکسی، API سازگار OpenAI/Anthropic و کل رابط کاربری را در قالب HTML رشته‌ای داخل همان فایل سرو می‌کند؛ با `node` `app.js` روی هر ماشینی بدون `npm install` اجرا می‌شود.

هر دو نسخه علاوه بر رابط چت، یک API کامل سازگار با OpenAI و Anthropic نیز ارائه می‌دهند (`/v1/models`، `/v1/messages`، `/v1/chat/completions`) تا از هر کلاینت استاندارد – SDK رسمی، curl، ابزارهای شخص ثالث – بتوان به مدل‌های سرویس دسترسی داشت. احراز هویت با کلیدهای سبک OpenAI و Anthropic انجام می‌شود که به‌صورت خودکار ساخته و در `api-keys.json` ذخیره می‌گردند.

پیش‌نیازهای سیستم | System Requirements

نیازمندی	نسخه Next.js	نسخه تک‌فایل (app.js)
Runtime	Node.js ≥ 20 (توصیه: ۲۴) یا Bun ≥ 1.3	Node.js ≥ 18 (فقط ماژول‌های داخلی http/https/fs/crypto)
Package Manager	bun (توسعه و تست با bun 1.3.14) یا npm	هیچ – بدون نصب پکیج اجرا می‌شود
فضای دیسک	حدود ۶۰۰MB (node_modules)	حدود ۱۲۰KB (app.js + api-keys.json)
شبکه	آپستریم freemodels + fonts.googleapis.com	فقط آپستریم (لوگوها base64 داخل فایل‌اند)
سیستم‌عامل	هر سیستم‌عامل دارای Node – Linux / macOS / Windows	
پورت	3000 (قابل تغییر با -p)	3000 پیش‌فرض · تغییر با PORT=xxxx

نسخه تک‌فایل عمدهً به‌جای `fetch` از `node:https` استفاده می‌کند تا بتواند هدرهای `Origin` و `Referer` (که در `fetch` استاندارد ممنوع‌اند) را واقعاً ارسال کند؛ بنابراین روی هر Node ≥ 18 بدون هیچ پیش‌نیاز دیگری کار می‌کند.

نصب و اجرا | Installation & Run

۳.۱ – نسخهٔ Next.js

```
# نصب وابستگی‌ها (bun) یا معادل npm/pnpm
bun install

# اجرای محیط توسعه روی پورت 3000 (dev.log لاگ در)
bun run dev # → http://localhost:3000

# و اجرا (standalone) بیلد پروداکشن
bun run build
bun run start # bun .next/standalone/server.js
```

۳.۲ – نسخهٔ تک‌فایل (app.js)

```
node app.js # پورت 3000
PORT=8080 node app.js # پورت دلخواه
node --check app.js # بررسی صحت سینتکس (قبل از هر استقرار)
```

۳.۳ – متغیرهای محیطی | Environment Variables

متغیر	پیش‌فرض	توضیح
PORT	3000	پورت سرور (فقط نسخهٔ app.js)
OPENAI_API_KEY	مقدار api-keys.json	override کلید سبک OpenAI
ANTHROPIC_API_KEY	مقدار api-keys.json	override کلید سبک Anthropic

۳.۴ – رفتار اولین اجرا | First-Run Behavior

در اولین اجرا (هر دو نسخه) اگر `api-keys.json` وجود نداشته باشد، دو کلید جدید ساخته و کنار پروژه ذخیره می‌شود (600 permission). اگر فایل موجود باشد همان کلیدها لود می‌شوند و هر دو نسخه دقیقاً همان کلیدها را می‌پذیرند. نسخهٔ Next.js همین فایل را از طریق `src/lib/apikeys.ts` (با کش در حافظه) می‌خواند، پس کلیدها بین دو نسخه یکسان می‌مانند.

مرورگر — UI چت (page.tsx / HTML داخلی app.js)

RTL فارسی · تم تاریک #0b1220 · پیکر مدل گروهی · تفکر · جست‌وجوی عمیق · استریم · Raw SSE · سایدبار

▼ POST /api/chat · GET /api/ping · GET /api/keys ▼

سرور — Next.js route handlers | app.js handlers

سقف بدنه (413) 5MB · جعل هدرهای مرورگر · pipe · timeout 180s · node:https · مستقیم استریم · خطا 502/504
به‌علاوه سه اندپوینت /v1* که پاسخ آپستریم را به فرمت استاندارد OpenAI یا Anthropic بازتولید می‌کنند

▼ POST https://freemodels-chat.freemodels.workers.dev/ (Origin: freemodels.pro) ▼

آپستریم — freemodels

۷ مدل · پاسخ SSE سبک (delta.content + delta.reasoning_content) OpenAI

شکل ۱ — جریان درخواست از مرورگر تا آپستریم؛ اندپوینت‌های /v1 پاسخ را نرمال‌سازی می‌کنند، نه صرفاً عبور خام.

۴.۲ — اتصال آپستریم | Upstream Connection

- **URL آپستریم:** `https://freemodels-chat.freemodels.workers.dev/` — ثابت در `src/lib/upstream.ts` و معادلش در `app.js`.
- **جعل هدرهای مرورگر:** `UA`، `Referer: https://freemodels.pro/`، `Origin: https://freemodels.pro`، `Accept-Encoding: identity` و `sec-fetch-*` و `sec-ch-*` تا پاسخ فشرده نباشد و `pipe` مستقیم بدون `decompress` ممکن شود.
- **چرا `node:https`؟** مرورگرها و `fetch` ارسال دستی `Origin/Referer` را ممنوع می‌کنند؛ برای عبور از `CORS` آپستریم باید این هدرها واقعاً روی سیم برود. این تصمیم در `Task 1` گرفته شد و در هر دو نسخه رعایت شده است.
- **پایداری استریم:** پاسخ تکه‌به‌تکه (بدون تجمیع بافر) رد می‌شود؛ `Cache-Control: no-cache, no-transform` و `X-Accel-` و `Buffering: no` ست می‌شود تا پروکسی‌های میانی بافر نکنند. قطع کلاینت ← `destroy` فوری آپستریم.

فایل	نقش
src/app/page.tsx	کل UI چت (~۹۰۰ client component خط): سایدبار، هدر، پیکر مدل گروهی، کامپوزر، پیام‌ها، مودال تنظیمات، Raw SSE
src/app/layout.tsx	· dir=rtl · lang=fa · فونت Vazirmatn (لینک مستقیم Google Fonts) · متادیتا
src/app/globals.css	اسکرول‌بار سفارشی، کرسر چشمک‌زن استریم، توکن‌های هایلایت کد، باکس تفکر، استایل‌های *-md
src/app/error.tsx	مرز خطای فارسی برای جلوگیری از کرش کل صفحه
src/lib/upstream.ts	ثابت‌های آپستریم + هدرهای جعلی + (node:https, timeout 180s) + openUpstream + لاگ رنگی + CORS باز
src/lib/sse.ts	پارسر جهانی SSE آپستریم: سبک OpenAI delta، فیلدهای مستقیم، [DONE]، reasoning_content/reasoning/thinking، خطای داخل استریم، تجمیع JSON ناقص
src/lib/markdown.ts	رندر مارک‌داون امن بدون کتابخانه: escape کامل، بلوک کد + هایلایت + دکمهٔ کپی، کرسر چشمک‌زن
src/lib/models.ts	FM_MODELS (۷ مدل + گروه) + resolveModelId — منبع واحد UI و اندپوینت‌های v1/
src/lib/apikeys.ts	ساخت/لود (mode 600) api-keys.json با override env · اعتبارسنجی · bearerFrom
src/lib/v1.ts	· readAll · flattenContent · SSE_HEADERS · V1_CORS (سقف 8MB) · estTokens
src/app/api/*	chat (پروکسی استریم داخلی) · ping (تست اتصال) · keys (کلیدها برای مودال)
src/app/v1/*	models · chat/completions (OpenAI) · messages (Anthropic)
app.js	نسخهٔ تک‌فایل (3082 خط): PAGE_CSS/PAGE_JS/PAGE_HTML + هندلرهای همان ۶ مسیر + بنر رنگی — بدون هیچ پکیج
api-keys.json	کلیدهای مشترک هر دو نسخه (permission 600)
public/	۴ لوگوی واقعی ارائه‌دهنده — در app.js به‌صورت base64 داخل EMBEDDED_LOGOS هم embed شده‌اند
scripts/embed_logos.py	ابزار بازتولید بلوک EMBEDDED_LOGOS (بهینه‌سازی base64 + 96px)
worklog.md	گزارش کار تسک‌به‌تسک (منبع بخش ۸)

SECTION 05

قابلیت‌ها | Features

۵.۱ — رابط چت | Chat UI

- **چیدمان:** سایدبار راست 260px (چت جدید، لیست گفتگوها با حذف، خروجی Markdown/JSON، پاک‌کردن همه با confirm) + drawer موبایل؛ هدر کنترل‌ها؛ کامپوزر چسبان.
- **پیکر مدل گروهی** (مطابق HTML واقعی سایت freemodels): سه گروه «Claude Pro / ChatGPT Pro / Other Pro Models» با آیکن‌های lucide، لوگوی 20px گردگوشه، ردیف انتخاب‌شدهٔ تیره #0A0A0B با تیک، hover #FFBF5، اسکرول داخلی، تارگت لمسی

44px، بستن با کلیک بیرون و Esc.

- **کنترل‌های هدر:** تفکر · جست‌وجوی عمیق · استریم · دکمه «اتصال؟» با ping خودکار · پنل Raw SSE (80KB) · مودال ⚙️ با System Prompt و بخش «🔗 اندپوینت‌های API و کلیدها» (کلیدها + کپی + نمونه curl) · نشانگر وضعیت سبز/زرد/قرمز.
- **پیام‌ها:** اکشن‌های hover (کپی/ویرایش اینلاین کاربر با حذف پیام‌های بعدی/حذف/بازتولید 🔄)، باکس جمع‌شونده «📝 فرایند تفکر مدل»، آمار 📊/🔗/📌، نشان «■ متوقف شد»، حباب قرمز خطا.
- **استریم زنده:** flush با requestAnimationFrame، کرسر چشمک‌زن، دکمه ارسال ↔ توقف (Esc + ■) با AbortController و destroy واقعی آپستریم.
- **حافظه:** localStorage با کلیدهای fm_chats / fm_settings؛ بارگذاری بعد از mount (بدون hydration mismatch)؛ صفحه خوش‌آمد با ۴ پیشنهاد.

۵.۲ – مارک‌داون و کد | Markdown & Code

رندر مارک‌داون دست‌ساز و امن است: ابتدا escape کامل HTML و سپس درج کنترل‌شده تگ‌ها. بلوک‌های کد با placeholder جداسازی می‌شوند و هدر زبان + دکمه «کپی» + هایلایت سینتکس ساده (کلیدواژه/رشته/عدد/کامنت) + dir=ltr دارند؛ کد اینلاین، بولد/ایتالیک/خط‌خورده/لینک (target=_blank)، هدینگ‌ها، لیست‌ها، نقل‌قول و خط افقی هم پشتیبانی می‌شوند. این منطق در `src/lib/markdown.ts` و معادلش در PAGE_JS یکسان است.

۵.۳ – سرور API | API Server

هر دو نسخه سه اندپوینت استاندارد + دو مسیر داخلی را سرو می‌کنند (جزئیات بخش ۷) و خطاها را دقیقاً در فرمت JSON همان API مقصد برمی‌گردانند – error.message/type/code برای OpenAI و error.type/message برای Anthropic. همه مسیرها CORS باز شامل هدرهای احراز هویت دارند.

SECTION 06

مدل‌ها | Models

منبع واحد لیست مدل‌ها (Next) `src/lib/models.ts` و ثابت `FM_MODELS` (app.js) است؛ هم پیکر UI و هم اندپوینت‌های v1/ از همین می‌خوانند و همیشه همگام‌اند. مدل پیش‌فرض: **claude-fable-5.1**.

Group	Vendor	Display Name	Model ID
Claude Pro	Anthropic	Claude Sonnet 5	claude-sonnet-5
Claude Pro	Anthropic	Claude Fable 5	claude-fable-5
Claude Pro	Anthropic	★ Claude Fable 5.1 پیش‌فرض	claude-fable-5.1
ChatGPT Pro	OpenAI	GPT 5.6 Sol	gpt-5.6-sol
ChatGPT Pro	OpenAI	GPT 5.6 Terra	gpt-5.6-terra
Other Pro Models	Z.AI	GLM 5.2	glm-5.2
Other Pro Models	Moonshot AI	Kimi K3	kimi-k3

تطبیق نرم نام مدل (resolveModelId): ورودی trim و lowercase و تبدیل فاصله/آندرلاین به خط تیره می‌شود و نام نمایشی هم پذیرفته است – «claude_fable 5.1»، «Claude Fable 5.1» و «claude-fable-5.1» هر سه به یک id نرمال می‌شوند. ورودی ناشناخته دست‌نخورده عبور می‌کند و ورودی خالی ← مدل پیش‌فرض.

۷.۱ – احراز هویت | Authentication

اندپوینت	هدر
/v1/models · /v1/chat/completions	Authorization: Bearer <key>
/v1/messages	anthropic-version + (Bearer یا همان x-api-key: <key> اختیاری)
/api/chat · /api/ping	بدون احراز هویت (اب داخلی)

هر دو کلید روی هر دو اندپوینت پذیرفته می‌شوند. کلیدهای فعلی (از `api-keys.json`):

```
{
  "openai": "sk-ItqvFVBt8slw2vqxPuW9oLiSyGGgC29lNYeET64dIzJ04e50",
  "anthropic": "sk-ant-api03-9lamB2K7KoYT8fw8tAp2CKL5kKs0HKhN4mE9eawuzRuW0aU3umJirsEFbS3B6RCjLRw8lrJ0YRmsnxECIu3nHaKM"
}
```

۷.۲ – GET /api/ping – تست اتصال

درخواست سبک stream:false با پیام ping به آپستریم می‌فرستد (تایم‌اوت ۲۰ ثانیه) و برمی‌گرداند:

```
{ "status": "ok", "ms": 2635, "sample": "... اولین 200 کاراکتر پاسخ یا خطای آپستریم..." }
```

۷.۳ – POST /api/chat – پروکسی داخلی

```
POST /api/chat
{ "messages": [{"role": "user", "content": "سلام"}],
  "modelId": "claude-fable-5.1", "thinking": false, "deepSearch": false, "stream": true }
→ عبور کد آپستریم (مثلاً 429) · (timeout 180s) 504 · (خطای اتمال) 502 · (MB بدنه < 5) خطاها: 413
→ عبور مستقیم SSE آپستریم (OpenAI سبک) delta.reasoning_content / delta.content
```

۷.۴ – GET /v1/models – لیست مدل‌ها

```
curl -s http://localhost:3000/v1/models \
  -H "Authorization: Bearer sk-ItqvFVBt8slw2vqxPuW9oLiSyGGgC29lNYeET64dIzJ04e50"

{ "object": "list", "data": [
  { "id": "claude-sonnet-5", "object": "model", "created": 1789321278, "owned_by": "freemodels-anthropic" },
  { "id": "claude-fable-5", "object": "model", "created": 1789321278, "owned_by": "freemodels-anthropic" },
  { "id": "claude-fable-5.1", "object": "model", "created": 1789321278, "owned_by": "freemodels-anthropic" },
  { "id": "gpt-5.6-sol", "object": "model", "created": 1789321278, "owned_by": "freemodels-openai" },
  { "id": "gpt-5.6-terra", "object": "model", "created": 1789321278, "owned_by": "freemodels-openai" },
  { "id": "glm-5.2", "object": "model", "created": 1789321278, "owned_by": "freemodels-z.ai" },
  { "id": "kimi-k3", "object": "model", "created": 1789321278, "owned_by": "freemodels-moonshot-ai" }
] }
```

فیلدهای /group/ لوگو عمداً در پاسخ نیستند تا فرمت استاندارد OpenAI حفظ شود؛ آن‌ها فقط برای ال‌ها هستند. بدون کلید ← 401

.invalid_api_key

- **فیلدها:** model (نرمال نرم؛ خالی ← پیش‌فرض)، messages (اجباری)، stream، stream_options.include_usage + دو اکستنشن غیراستاندارد: deep_search و thinking.
- **غیراستریم:** آبجکت کامل chat.completion با choices[].message.content و usage تخمینی (~۴ نویسه = ۱ توکن).
- **استریم:** چانک نقش ← دلتاها (content و در صورت وجود reasoning_content) ← چانک "finish_reason": "stop" ← چانک usage (در صورت data: [DONE] ← (include_usage

```
curl -N http://localhost:3000/v1/chat/completions \
-H "Authorization: Bearer sk-ItqvFVBt8slw2vqxPuW9oLiSyGGgC29lNYeET64dIzJ04e50" \
-H "Content-Type: application/json" \
-d '{"model": "claude-fable-5.1", "messages": [{"role": "user", "content": "سلام"}], "stream": true}'
```

Anthropic سازگار – POST /v1/messages – ۷.۶

- طبق قوانین Anthropic فیلدهای model و max_tokens **اجباری‌اند** (نبود ← 400 با پیام "model: Field required" / "max_tokens: Field required").
- system به صورت رشته یا آرایه بلوک پذیرفته می‌شود و به یک پیام system تبدیل می‌گردد.
- **غیراستریم:** آبجکت message با بلوک‌های {"type": "thinking"} (در صورت وجود) و {"type": "text"} + usage + "stop_reason": "end_turn".
- **استریم:** چرخه کامل ping → message_start → (content_block_delta + text_delta / thinking_delta) → message_delta → message_stop → *(content_block_stop

```
curl -N http://localhost:3000/v1/messages \
-H "x-api-key: sk-ant-api03-9lamB2K7KoYT8fw8tAp2CKL5kKs0HKhN4mE9eawuzRuW0aU3umJirsEFbS3B6RCjLRw8lrJ0YRmsnxECIu3nHaKM" \
-H "anthropic-version: 2023-06-01" -H "Content-Type: application/json" \
-d '{"model": "claude-fable-5.1", "max_tokens": 1024, "messages": [{"role": "user", "content": "سلام"}], "stream": true}'
```

۷.۷ – فرمت خطاها | Error Formats

سبک	ساختار
OpenAI-style	<code>{"error": {"message": "invalid_request_error api_error", "param": null, "code": "invalid_api_key"}}</code>
Anthropic-style	<code>{"type": "error", "error": {"type": "authentication_error invalid_request_error rate_limit_error api_error", "message": "..."}}</code>
نگاشت کدها	خطای اتصال ← 502 · تایم‌اوت ← 504 · 429 آپستریم ← همان 429 (rate_limit_error در سبک Anthropic)

SECTION 08

تاریخچه توسعه | Development History

پروژه در هفت تسک متوالی ساخته و تأیید شده است؛ گزارش کامل هر تسک با جزئیات تست در `worklog.md` موجود است و چک‌لیست صحت‌سنجی برای تغییرات آینده در `HANDOFF.md` آمده است.

#	تسک	نکته ماندگار
۱	بک‌اند پروکسی /api/ping/ + api/chat + کتابخانه‌های مشترک (upstream/sse/markdown)	تصمیم node:https به جای fetch برای هدرهای جعلی
۲	فرانت‌اند کامل RTL فارسی (+ page.tsx + layout + globals.css) (error.tsx)	بدون hydration mismatch؛ حافظه localStorage
۳	تأیید end-to-end با مرورگر headless	استریم ۲۸۶ تکه/۱۹ ثانیه؛ توقف/بازتولید/ویرایش/خروجی/موبایل ✓
۴	نسخه تک‌فایل app.js (پورت کامل منطق، بدون پکیج)	۲۰۵۸ خط؛ رعایت قیود PAGE_JS
۵	تأیید مستقل app.js + جمع‌بندی	تست ۶ مسیر + 413 بدنه بزرگ + eslint ignore
۶	۷ مدل جدید + کلیدهای API + سه اندپوینت /v1 در هر دو نسخه	منبع واحد FM_MODELS؛ مودال 🗝 اندپوینت‌ها و کلیدها
۷	بازيابی workspace از tar + پیکر مدل گروهی مطابق سایت freemodels	۴ لوگوی واقعی؛ رفع باگ z-index stacking؛ embed؛ base64

SECTION 09

مشکلات شناخته‌شده و نقشه راه | Known Issues & Roadmap

۹.۱ – مشکلات شناخته‌شده | Known Issues

- **خطای موقت 429 آپستریم** («Service temporarily overloaded» / «providers exhausted»): رفتار سرویس رایگان است، نه باگ پروژه. هر دو نسخه آن را شفاف به حباب قرمز (UI) یا کد/فرمت استاندارد (API) تبدیل می‌کنند و retry پس از چند ثانیه معمولاً موفق است.
- **فرمت پاسخ آپستریم قفل به سبک OpenAI فعلی است:** پارسر sse.ts جهانی طراحی شده، اما اگر آپستریم ساختارش را تغییر دهد اولین نقطه بررسی همین فایل (و معادل makeUpstreamParser در app.js) است.
- **وابستگی فونت به شبکه در نسخه Next:** فونت Vazirmatn با لینک مستقیم Google Fonts لود می‌شود (تصمیم عمدی برای مقاومت به قطعی نصب)؛ در محیط بدون اینترنت UI با فونت جایگزین رندر می‌شود. نسخه app.js این مشکل را ندارد.
- **usage تخمینی است** (~۴ نویسه = ۱ توکن) چون آپستریم usage واقعی نمی‌دهد.

۹.۲ – مسیر پیشنهادی ادامه | Roadmap

- **Retry خودکار با backoff** برای 429 آپستریم در لایه پروکسی – بهترین بهبود تجربه کاربر.
- **افزودن فیلدهای group/vendor به v1/models/** به صورت extension اختیاری (سازگاری OpenAI حفظ می‌شود).
- **استقرار پروداکشن:** bun run build + اجرای standalone پشت reverse proxy (با X-Accel-Buffering: no) یا node app.js با systemd/pm2.
- **تست‌های خودکار:** اسکریپت smoke برای ۶ مسیر (فعلاً چک‌لیست دستی در 5 § HANDOFF.md).
- **چندکاربره‌سازی (اختیاری):** محدودسازی نرخ و احراز هویت جدا برای api/chat/ در صورت عمومی‌شدن اپ.

این سند همراه با **README.md** (منبع Markdown همین محتوا) و **HANDOFF.md** (سند تحویل سریع برای توسعه‌دهنده/ایجنت بعدی) نگهداری می‌شود؛ پس از هر تغییر مهم در پروژه، هر سه فایل را همگام به‌روزرسانی کنید. گزارش خام تسک‌ها و جزئیات تست‌ها در **worklog.md** در دسترس است.